

Rapport de Projet - Algorithmique 2

RAMDANI Ferhat

15 juin 2024

Ce rapport présente les résultats de mon travail dans le cadre du projet d'algorithmique 2 portant sur la **Vérification de mots de passe à l'aide d'un filtre de Bloom**.

1 Manuel

Pour lancer le programme, il faut lancer les deux commandes suivantes :

- Compilation : `make`
- Exécution : `./main`

Au lancement du programme, un menu sera affiché, expliquant les différentes commandes qui peuvent être exécuté par le programme :

```
Menu usage :
-----Basic commands-----
    c <m> <k>:      Create filter with parameters m and k
    i <entry>:      Insert <entry> into the current filter
    f <entry>:      Find <entry> in the current filter
    d:             Display the filter

-----Test and File commands-----
    g <size>:       Generate <size> random words and stores them in words\generated.txt
    v <m> <k> <keys_file> <test_file>:   Verify existence of entieres of <test_file>
in a new filter filled with the entries of <keys_file> with parameters <m> and <k> and disp
lay false-postive rate
    r <filename>:   Read the file <filename> in the current filter
    t:             Launch tests with various m and k and displays statistics
    s:             Display space and time comparaisons between bloom filter, hashmap a
nd binary searh tree

-----Help and Quit commands-----
    h:            Print menu
    q:            Quit the menu
```

FIGURE 1 – Capture d'écran de menu du programme

2 État du projet

Globalement, les fonctionnalités requises pour le filtre de bloom ont été implantées dans le programme et marchent correctement. En particulier, le programme développé dans le cadre de ce projet permet

- La création d'un filtre de bloom avec des paramètres m et k .
- L'insertion d'une entrée dans le filtre.
- La recherche d'une entrée dans le filtre.
- L'affichage du filtre.
- L'insertion d'une banque de mots (dans un fichier) dans le filtre.
- La recherche d'une banque de mots (dans un fichier) dans le filtre et calcul du taux de faux positif résultant de ces recherches.
- La génération d'une baque de mots avec entrées aléatoires

Ce programme a été testé sur `1000words.txt` fournie sur e-learning.

Aucune amélioration n'a été tentée ou implantée, principalement parce que je n'ai pas de binôme.

3 Analyse et Observation

Le filtre de Bloom peut être caractérisé par deux paramètres fondamentaux, notés m et k , où m représente la taille du tableau binaire du filtre et k désigne le nombre de fonctions de hachage utilisées.

Une valeur élevée de m permet d'augmenter la capacité du filtre et donc d'accueillir un plus grand nombre de mots clés. En revanche, une valeur élevée de k améliore la précision en réduisant le taux de faux positifs, car il est moins probable que deux clés différentes génèrent les mêmes k valeurs de hachage. Toutefois, une augmentation excessive de k peut entraîner un remplissage trop rapide du filtre, car le nombre de bits à positionner à chaque insertion augmente.

Ces observations se reflètent dans les résultats suivants :

En fixant m à 500, 1000, 1500, ..., jusqu'à 20000, et en faisant varier k de 1 à 40 pour chaque valeur de m , nous obtenons les courbes suivantes :




FIGURE 2 – taux de faux positifs pour m fixé et k variant

Il est clairement observable que le taux de faux positifs augmente avec l'augmentation de k sur toutes les courbes précédentes, ce qui confirme nos attentes.

En examinant à présent les graphiques suivants, où je fixe les valeurs de k de 1 à 39 et fais varier m de 500 à 20000 pour chaque valeur de k fixée, nous obtenons les courbes suivantes :




FIGURE 3 – taux de faux positifs pour k fixé et m variant

On remarque que toutes les courbes précédentes sont décroissantes, ce qui suggère que le taux de faux positifs diminue lorsque la taille m augmente.

Il est à noter que pour de grandes valeurs de k (voir le graphe (t)), le taux de faux positifs est très élevé pour de petites valeurs de m , ce qui démontre également que le nombre de fonctions de hachage k est dans ce cas trop élevé pour une valeur de m aussi réduite.

Lorsque l'on compare la valeur expérimentale obtenue par le programme avec la valeur théorique calculée avec la formule :

$$k \approx \frac{m}{n} \ln(2) \quad (1)$$

On retrouve la courbe suivante :





FIGURE 4 – Meilleur valeur théorique vs calculée de k


La figure 4 montre bien que les valeurs calculées du meilleur k pour chaque valeur de m s'approche de la valeur théorique calculée avec la formule 1.

Afin de vérifier l'efficacité de notre filtre de bloom, on peut la comparer avec d'autres structures de données, dans la suite, on va réaliser des comparaisons d'espace et de temps entre le filtre de bloom, une table de hachage et un arbre binaire de recherche.

La figure suivante montre cette comparaison en temps entre ces 3 structures, en montrant le temps nécessaire pour réaliser chacune des insertions de 50000, 100000, 150000, ..., jusqu'à 400000



En temps



En espace

FIGURE 7 – Comparaison des 3 structures en temps et espace

On observe ici que le filtre de bloom s'approche en temps à la structure table de hachage, bien que cette dernière soit plus rapide. De l'autre côté, le filtre de bloom prend de loin le moins d'espace parmi les 3 structures. Ces courbes montrent que dans la pratique, le filtre de bloom exhibe des résultats très intéressants, aussi bien en temps qu'en espace.

4 Déroulement

Ayant été seule dans ce projet, c'était plus simple pour moi de m'organiser et d'avancer à mon propre rythme.

Lors de la soutenance Bêta, notre chargé de TP a apprécié la démarche que j'ai entreprise pour l'étude de la partie 4 (Sélection des paramètres). Je n'ai pas eu de retours négatifs nécessitant des modifications à réaliser au niveau de mon code.

5 Conclusion

Le filtre de Bloom, à l'instar de toute autre structure de données, présente des avantages et des inconvénients.

Dans ce travail, j'ai exploré l'implémentation de cette structure de données, étudié ses points forts et ses points faibles, et l'ai comparée à d'autres structures. Bien que certaines améliorations auraient pu être apportées, le manque de temps et le fait que j'ai réalisé ce travail seule ont limité ces possibilités.